



주제탐구세미나 (DLS101)

Lecture 5. 데이터 분석

측정된 데이터를 정리하고 해석하여 설명과 예측으로 연결한다.

Prof. Jiyoung Lee
Department of Chemical Engineering
Ajou University

1. 측정에서 시작된 데이터가 공학적 판단으로 연결되는 분석 흐름을 이해한다.
2. 데이터 정리와 분류가 모델 선택과 결과 해석에 미치는 영향을 설명할 수 있다.
3. 모델링 결과를 바탕으로 미래 거동을 예측하는 기본 개념을 이해한다.
4. 이론식과 경험식의 차이를 이해하고, 각각이 사용되는 상황을 구분할 수 있다.

Data Analysis Pipeline

- 데이터 분석의 기본 흐름: 측정 → 정리 → 모델링 → 예측

측정 (Measurement)

수치, 데이터를 얻는다

- 5 m 높이에서 공을 떨어뜨리고 시간을 측정한다
- 여러 번 반복하여 데이터를 얻는다
예: 0.98 s / 1.03 s / 1.01 s / 0.99 s

정리, 분류 (Organization)

측정값을 정리한다. 숫자의 의미를 맞춤

- 측정값을 표로 정리한다
- 평균값과 편차를 확인한다
- 이상값(outlier)을 찾는다

실험	1	2	3	4
낙하 시간(s)	0.98	1.03	1.01	0.99

모델링 (Modeling)

왜 그런 값이 나왔는지 설명한다.

- 데이터를 참값과 비교한다
- 상관관계를 파악한다
- 데이터를 해석한다 (오차 판단: 공기저항, 측정 오차, 반응속도)

예측 (Prediction)

다음 상황을 예상한다

- 높이를 10 m로 바꾸면?
- 다른 물체를 사용하면?
- 바람이 불면? 새로운 조건에서 결과를 예상한다


데이터, 어디서 왔을까? — 측정 (Measurement)

- 1) **측정 단계:** 데이터 분석의 토대이자 가장 중요한 출발점. 우리가 주변 세상을 이해하기 위해 눈, 귀, 코 등 감각 기관을 사용하듯, 공학에서는 설문(survey), 실험(experiment) 등 다양한 방법으로 데이터를 수집해야 함.

• **핵심 고려 사항: "무엇을, 어떻게, 얼마나 자주 측정할 것인가?"**

- 측정 대상(변수), 측정 도구, 측정 주기를 명확히 정해야 함.
- 측정 단위($^{\circ}\text{C}$, m/s, N 등)와 정밀도(precision)도 반드시 기록해야 함.

좋은 측정	나쁜 측정
같은 기준	기준이 흔들림
반복 가능	결과 재현 어려움
오차 원인 파악 가능	해석 어려움



데이터, 어떻게 다듬을까? — 정리, 분류

2) 정리 단계: 원석(raw data)을 보석(clean data)으로 만드는 과정. 측정 과정에서는 누락, 오류, 형식 차이, 중복이 함께 발생할 수 있음. 분석 전에 어떤 기준으로 정리할 것인지 결정 필요

• 핵심 고려 사항: 해석 가능한 상태로 만드는 단계 → 데이터의 의미를 고려해야 함



- 결측치 처리 (Missing Values): 데이터 중 일부가 비어 있는 경우
예) 센서 미작동, 기록누락, 잘못된 데이터 수집 조건

- 처리 방법: 평균값(mean) 또는 중앙값(median)/ 앞/뒤 값 사용, 해당 데이터 삭제

* 왜 비어 있는지 먼저 판단하는 것이 중요함

- 센서 오류인지
- 실제 측정 불가능 구간인지
- 실험 자체가 실패한 것인지

“빈칸도 정보일 수 있음”

데이터, 어떻게 다듬을까? — 정리, 분류

- **이상치 처리 (Outlier Detection):** 정상 범위를 크게 벗어난 값


예) 사람 체온($^{\circ}\text{C}$) 데이터: 36.5, 36.7, 36.6, 150.0

- 처리 방법: 허용 범위를 벗어나면 제거, 박스플롯(IQR) 기준 사용

- 왜 비어 있는지 먼저 판단하는 것이 중요함

- 센서 오류인지
- 실제 측정 불가능 구간인지
- 실험 자체가 실패한 것인지

“이상치 하나가 새로운 발견이 될 수도 있음”




데이터, 어떻게 다듬을까? — 정리, 분류

*박스플롯(IQR): 데이터의 중앙값, 분포를 보여주는 그래프

<https://develsw.tistory.com/101>

전체 분포 속에서 어느 값이 비정상적으로 떨어져있는지 쉽게 파악 가능



Q) 35가 이상치임을 판단하시오

데이터: 12, 13, 14, 15, 15, 16, 17, 18, 19, 35

$Q1 = 14$


$\text{Median} = 15.5$

$Q3 = 18$

$\text{IQR} = 18 - 14 = 4$

→ 상한: $18 + 1.5 \times 4 = 24$

따라서 35는 이상치에 해당




데이터, 어떤 의미를 내포할까? — 모델링


3) 모델링 단계: 정리된 데이터를 바탕으로 숨겨진 패턴과 변수 간의 관계를 수학적으로 표현하는 것. 엔지니어는 데이터를 분석해 자연현상이나 시스템의 법칙을 발견함.

- **핵심 고려 사항:** 데이터 사이의 관계를 어떤 수식 또는 함수로 표현할 수 있겠는가


평활: 데이터의 흔들림을 줄여 추세를 보기 쉽게 만드는 것




회귀: 데이터 사이 관계를 수식으로 설명하는 것



왜 평활(smoothing)이 필요한가?



$$\text{Measured Data} = \text{True Signal (S)} + \text{Noise (N)}$$



J. Org. Chem. 2024, 89, 22, 16586-16593


- 많은 반복 실험/데이터 포인트가 필요함: noise 속에서 signal을 분리

평활의 종류와 특징

다양한 평활 기법이 존재하며, 데이터의 특성과 분석 목적에 따라 적합한 방법을 선택해야 함.


단순 이동 평균 (Moving Average)

윈도우 내 모든 값에 **동일한 가중치**를 부여함. 계산이 단순하고 직관적이지만 과거 데이터와 최근 데이터를 동등하게 취급함.




가중 이동 평균 (Weighted Moving Average)

최근 값에 **더 높은 가중치**를 부여함. 최근 변화에 더 민감하게 반응하므로 트렌드 추적에 유리함.






사비츠키-골레이 (Savitzky-Golay) 필터

윈도우 내 데이터에 **다항식을 피팅**하여 평활함. 피크나 폭 등 데이터의 특성을 더 잘 보존하는 장점이 있음.



핵심 질문: 얼마나 평활할 것인가?




너무 적게 → 잡음이 그대로 남음

너무 많이 → 중요한 변화도 사라짐

회귀(Regression): 데이터 관계를 식으로 표현하기







- 회귀는 두 변수 사이의 관계를 수학적 식으로 나타내는 방법임



회귀 종류: 데이터 형태에 따라 달라진다

- 데이터가 어떤 패턴을 보이는지에 따라 적합한 회귀 모델이 달라짐.



회귀 종류: 데이터 형태에 따라 달라진다

- 데이터가 어떤 패턴을 보이는지에 따라 적합한 회귀 모델이 달라짐.

1. 선형 회귀 (Linear)

$$y = ax + b$$

- 변화율이 일정한 데이터에 적합함
- 가장 단순하고 해석이 쉬우며, 계수 a 가 기울기를 나타냄
- 예: 시간에 따른 일정한 성장

2. 다항 회귀 (Polynomial)

$$y = ax^2 + bx + c$$


- 변화율이 달라지는 비선형 데이터에 적합함
- 차수(degree)를 높일수록 더 복잡한 곡선을 표현하지만 과적합(overfitting) 위험이 있음.
- 예: 포물선 운동

3. 지수 회귀 (Exponential)

$$y = ae^{bx}$$

- 현재 값에 비례하여 변화하는 데이터에 적합함.
- 인구 성장, 바이러스 확산, 복리 계산 등에서 자주 나타나는 패턴임.
(로그모델: $y = a \cdot \ln(x) + b$)

회귀 결과는 얼마나 믿을 수 있는가? — R^2



잔차 (Residual)

실제값 - 예측값
잔차가 작을수록 모델이 데이터에 잘 맞는 것

최소자승법 (Least Squares)

잔차의 제곱합이 최소가 되는 선을 찾는 방법
(제곱을 쓰는 이유: 양·음 잔차가 상쇄되지 않게)


R^2 (결정계수)

모델이 데이터를 얼마나 잘 설명하는가
0~1 사이 값 — 1에 가까울수록 좋음

주의


R^2 이 높다고 무조건 좋은 모델이 아니다 — 차수를 높이면 R^2 은 항상 올라간다.

회귀 결과는 얼마나 믿을 수 있는가?




과소적합 (Underfitting)

모델이 너무 단순하여
데이터의 경향을
나타내지 못함



적정 모델 (Good Fit)

데이터의 핵심 경향을
나타내면서 노이즈는
걸러냄. 가장 적합한
모델형태.



과적합 (Overfitting)


훈련 데이터의 noise
까지 학습한 과도한
피팅. 새로운 데이터
예측이 어려움

데이터, 새로운 정보를 줄 수 있는가? — 예측

4) **예측 단계:** 모델을 만든 뒤에는 직접 측정하지 않은 지점의 값도 추정할 수 있음. 회귀를 통해 데이터의 관계를 식으로 표현하면, 추정 위치에 따라 내삽(Interpolation)과 외삽(Extrapolation)으로 구분됨.

내삽 (Interpolation)

측정된
데이터 범위 안에서
값을 추정




외삽 (Extrapolation)

측정 범위를 넘어
값을 예측

내삽 (Interpolation)

- 이미 측정한 데이터 **사이의 값**을 회귀식으로 계산하는 방법이다.
- 데이터 범위 내부에 위치하므로 모델이 실제 경향을 충실히 반영할 가능성이 높다.
- **내삽**은 이미 **확인된 경향 안에서 값을 읽는 과정**이다.



→ **비교적 안정적**


데이터 범위 안에 있으므로
경향 유지 가능성이 높음

→ **신뢰도 높음**

이미 확인된 구간에서 값을
읽는 과정

외삽 (Extrapolation)

- 측정된 데이터 범위를 벗어난 구간까지 **회귀식을 연장하여 값을 추정**하는 방법이다.
- 모델이 실제 시스템의 거동을 그대로 반영한다는 보장이 없다.
- **외삽은 모델을 사용하는 것이 아니라, 모델을 가정하는 과정에 가깝다.**



→ **경향 유지 불확실**

실제 거동이 범위 밖에서
달라질 수 있음

→ **오차 급증 가능**

예측 거리가 멀수록 불확실
성이 기하급수적으로 증가

이론식 · 경험식

이론식

- 원리 → 수식
 - 자연 법칙에서 논리적으로 유도
- "원리상 이렇게 나올 수밖에 없다"

경험식

- 관찰된 경향 → 수식
 - 반복 실험 데이터를 일반화
- "여러 번 해보니 보통 이렇게 나온다"

	이론식	경험식
출발점	물리 법칙	반복된 관찰
유도 방식	논리적 전개	데이터 피팅
적용 범위	이론 가정 범위	실험 범위
일반성	높음	중간

이론식

- 자연 법칙이나 물리·화학적 원리로부터 **논리적으로 유도된** 식임. 수식의 각 항이 무엇을 의미하는지 명확히 설명할 수 있음.

✓ 특징

- 수학적 전개 과정이 존재
- 각 항의 물리적 의미가 명확
- 가정이 분명하게 명시됨
- 범용성이 상대적으로 높음

✓ 대표 예시

- $PV = nRT$ — 이상기체 방정식
- **Clausius–Clapeyron** 식 — 열역학 유도
- 뉴턴 운동 법칙 — $F = ma$

- 실험과 관찰을 통해 반복적으로 나타나는 경향을 **데이터 피팅으로 일반화**한 식임. 이론에서 직접 유도되지 않았지만, 많은 데이터를 기반으로 하기 때문에 넓은 범위에서 신뢰할 수 있음.

✓ 특징

- 이론에서 직접 유도된 것이 아님
- 데이터 피팅으로 상수를 결정
- 특정 온도·압력·조건 범위에서 정확
- "왜 그런 형태인가?"가 반드시 설명되지 않음

대표 예시: 증기압 식

Table H.1 Vapor Pressures of Various Substances

Antoine equation:

$$\ln(p^*) = A - \frac{B}{C + T}$$

where p^* = vapor pressure, mm Hg

T = temperature, K

A, B, C = constants

Name	Formula	Range (K)	A	B	C
Acetic acid	$C_2H_4O_2$	290–430	16.8080	3405.57	–56.34
Acetone	C_3H_6O	241–350	16.6513	2940.46	–35.93
Ammonia	NH_3	179–261	16.9481	2132.50	–32.98
Benzene	C_6H_6	280–377	15.9008	2788.51	–52.36

예제. 활성화 에너지 계산

벤젠 디아조늄 클로라이드(benzene diazonium chloride)가 분해하여 클로로벤젠(chlorobenzene)과 질소를 생성하는 다음 1차반응에서




표 E3-1.1의 정보를 이용하여 활성화 에너지를 계산하여라.

표 E3-1.1 자료


k (s ⁻¹)	0.00043	0.00103	0.00180	0.00355	0.00717
T (K)	313.0	319.0	323.0	328.0	333.0

$$\ln k = \ln A - \left(\frac{E_a}{RT} \right)$$

figureE3-1

	A	B	C
1	k (s ⁻¹)	$\ln(k)$	$1/T$ (K ⁻¹)
2	0.00043	-7.75	0.00320
3	0.00103	-6.88	0.00314
4	0.00180	-6.32	0.00310
5	0.00355	-5.64	0.00305
6	0.00717	-4.94	0.00300

그림 E3-1.1 Excel 스프레드시트



Key takeaways

1. 측정된 데이터는 정리와 해석 과정을 거쳐 의미 있는 정보로 활용된다.
2. 데이터의 정리 방식은 이후의 분류와 모델 선택에 영향을 준다.
3. 모델링은 데이터 속 경향을 이해하고 예측 가능성을 높이는 과정이다.
4. 이론식과 경험식은 목적과 데이터 조건에 따라 다르게 사용된다.