

How to live in the world
full of massive unruly data

거대 데이터는 왜 나타나고
어떻게 길들여야 하나

2026년 봄학기 주제탐구세미나
박형주 (아주대 수학과)

Big Data 시대 도래하다

Each day, 2.5 quintillion bytes

(1 quintillion = 백경 = 백만조 = 백만 trillion)

of data are produced

- 현재 세계 데이터의 반 이상은 지난 2년 동안에 나온 것...
- 왜 갑자기 데이터가 많아졌지?
- 이전에 없던, 또는 인간이 모으지 않던 데이터를 IoT 등을 통해, 모으기 시작했기 때문

Homework due by May 10 (Tue)

To be submitted at Ajou BB

집에 스마트 계량기 설치

→ 전력 빅데이터 수집

→ 사용자에게 어떤 benefits을 줄 수 있을까?

큰 수의 표현: 서양과 동양

Abbr.	Prefix name	Decimal size	영어
k	kilo-	10^3	thousand
M	mega-	10^6	million
G	giga-	10^9	billion
T	tera-	10^{12}	trillion
P	peta-	10^{15}	quadrillion
E	exa-	10^{18}	quintillion

Suffix name	Decimal size
만	10^4
억	10^8
조	10^{12}
경	10^{16}
해	10^{20}

same




-The Signal & The Noise-

Historical Perspectives


신호:
진리, 진실

소음:
진리에 다가서지 못하게
우리의 정신을 방해하는 것



정보의 폭발적 증가에 기여한 Historical Events

- 정보의 폭증을 위한 전제조건: Hardware + Software



- **Hardware 마련:** 1440년, Johannes Gutenberg의 금속활자 발명
- **Software 마련:** 1517년, Martin Luther "95 Theses" 발표. 비텐베르크 교회 정문에 교황청의 면죄부 판매를 비판하는 라틴어 논제를 게시 → 종교개혁의 거대한 흐름
- 1524~1648: 유럽 내 전쟁의 시대. 독일 농민전쟁, 30년 전쟁, 프랑스 종교전쟁 (위그노 전쟁) 등... → 30년 전쟁에서만 독일 인구의 1/3이 사망하는 등, 유럽에서 수백만명 사망

정보의 폭발적 증가는 산업혁명으로 이어지고

- 정보와 지식의 폭증을 위한 전제조건인 마련과 전통적 권위 타파를 위한 전쟁을 겪으면서, 종교적 사상과 과학적 사상이 검열의 공포없이 유통되기 시작하고, 산업혁명의 기반 형성
- 1775년 증기기관 발명 → 프로테스탄트 국가와 자유언론이 확립된 국가를 중심으로 산업혁명 확산 → 300여년에 걸쳐 1인당 GDP의 폭발적 증가

The fatal attraction of Conspiracy Theory

음모론의 매력

Facts & Rumors

Nowadays, Social Networks are far more than person-to-person communication channels.

Facts and rumors are inseparably blended, with all sorts of conspiracy theories abound

Moon Landing Conspiracy

달착륙 음모론



WHY YOU SHOULD CARE

Because it's not only conspiracy theorists who can be fooled.

By Max Canard

THE DAILY DOSE • APR 01 2016

In this exclusive OZY confession, 81-year-old former Hollywood cameraman Max Canard comes clean about his role in what could be the greatest hoax ever carried out: the Apollo moon landing.

I first walked on the moon in the summer of 1965 — four full years ahead of Neil Armstrong. Of course, neither I nor the Apollo boys really set foot on the moon, but I suppose many of you suspected as much already.

≡ BUSINESS INSIDER DE

INTERNATIONAL

Stanley Kubrick's daughter debunks the myth that her father faked the Apollo 11 moon landing



Jason Guerrasio



6.07.2016, 19:49 10



Stanley Kubrick on the set of "The Shining." AP

Ever since the astronauts of Apollo 11 landed on the moon in 1969, people have theorized that it was all an elaborate hoax. In fact, some believe that it was a big Hollywood production helmed by one of the greatest directors of all time, Stanley Kubrick.

👍 Gefällt mir 0

🔗 Teilen 0

So when his daughter, Vivian Kubrick, tweeted support for NASA's Juno

RUMORS



녹차를 마시느니 갈레 짬 물을
마셔라

- 현미는 사람을 천천히 죽이는 독약이다

배추김치를 먹으면
머리가 나빠진다

- 두부 먹으면 몸이 썩어
죽는다

압력밥솥에 지은 밥은 죽음의
물질이다

These 'claims' are transmitted rapidly over social networks exploiting the fears deeply rooted in people's subconsciousness. However, the claims are often founded on small number of cases, and their small sample sizes make them statistically inconsequential.

(과장된 소문과 개인적 신념이 아닌) 데이터에서 답을 찾아야

이란 vs 미국의 출생률, 누가 더 높을까?

** 인구, 출생률, 낙태 등은 종교와 문화에 강한 영향을 받는다는 통념:

데이터에 따르면 소득에 가장 영향 받음

** 전쟁의 파괴성에 비해 질병의 위험 과소평가:

1차 세계대전의 사망자 보다 전쟁 직후인 1918년 스페인 독감 사망자가 더 많음 (세계 인구의 2.7%인 5천만명 사망)


** 범죄가 늘고 있다는 통념:

미국에서 10만명당 흉악 범죄 수: 2006년 473.6건 → 2025년 330건

한국에서 10만명당 전체 범죄 수: 2004년 4,328건 → 2024년 3,091건

** 극빈국에서의 유아사망이 증가하고 있다는 통념:

1950년 1440만명(사망률 15%) → 2014년 450만명 → 2015년 440만명 →



Changing World

세상의 변화

문과와 이과의 구별은 모호해지고

...

전통적인 문과 직업이던 마케팅 분야 종사자들은, 이제 경험에 의존하는 게 아니라 빅데이터를 사용해서, 소비자 선호도의 변화를 추적하고 다음 시즌의 상품 개발 전략을 세운다

사회과학자들은 이제 데이터 사이언스의 체계로 사회 현상을 분석한다.

과학자들에게 인문학적 글쓰기 능력은 더욱 중요한 자질이 되어가고 있다

경험과 직관만으론 안되는 일들이 늘어난다

...

예전엔 한 분야에 오랫동안 종사한 사람의 경험과 직관으로 많은 문제를 해결

➔ 빅데이터 폭증의 시대에는, 경험과 직관만으론 이 방대한 데이터에서 의미를 읽어내는 게 어려워짐

아마존의 물류혁신의 사례:

아마존은 빅데이터를 분석하던 중에, 기저귀를 시키면 맥주도 같이 시키는 경우가 많다는 걸 알게 됨

➔ 젊은 아빠들이 아이를 보는 일이 잦아지면서 일어나는 현상인 걸로 추측 ➔ 물류 창고의 저장 배열을 바꾸어 주문에 신속하게 대응

- 우리 경험이나 상식으로 예상하기 힘든 이러한 문화의 변화는, **문화 비평가들의 예리한 시선에서 관찰된 것이 아니라,** 빅데이터의 의미를 수학적 기법으로 읽어낸 것


➔ 답은 데이터 속에 숨어 있다



빅데이터 길들이기

- with a bit of Graph Theory & Wavelets -

구글은 어떻게 검색엔진의 초강자였던 야후를 넘어섰을까?



- PageRank: Google's secret weapon for powerful search
- **A mathematical algorithm for analyzing links**
- Named after Google cofounder Larry Page

PageRank is a [link analysis](#) algorithm and it assigns a numerical [weighting](#) to each element of a [hyperlinked set](#) of documents, such as the [World Wide Web](#), with the purpose of "measuring" its relative importance within the set. The [algorithm](#) may be applied to any collection of entities with [reciprocal](#) quotations and references. The numerical weight that it assigns to any given element E is referred to as the *PageRank of E* and denoted by $PR(E)$. Other factors like [Author Rank](#) can contribute to the importance of an entity.

A PageRank results from a mathematical algorithm based on the [webgraph](#), created by all World Wide Web pages as nodes and [hyperlinks](#) as edges, taking into consideration authority hubs such as [cnn.com](#) or [usa.gov](#). The rank value indicates an importance of a particular page. A hyperlink to a page counts as a vote of support. The PageRank of a page is defined [recursively](#) and depends on the number and PageRank metric of all pages that link to it ("[incoming links](#)"). A page that is linked to by many pages with high PageRank receives a high rank itself.

페이스북의 방식 & 한국 KT의 사례



EdgeRank

6. NFO: News Feed Optimization
EdgeRank

$$\sum_{\text{edges } e} u_e w_e d_e$$

u_e - affinity score between viewing user and edge creator
 w_e - weight for this edge type (create, comment, like, tag, etc.)
 d_e - time decay factor based on how long ago the edge was created



- The metropolitan city of Seoul collaborated with KT in order to find optimal routes of night-time buses
- Big data analytics was applied to the data of people's night time whereabouts → **optimal bus routing**

GE 프리딕스의 사례

- GE의 산업인터넷 소프트웨어 플랫폼 '프리딕스' → 하드웨어에 플랫폼 기반의 소프트웨어를 함께 판매하는 새로운 비즈니스 모델
- 자사 제트엔진 GE90에 프리딕스를 접목 → 부착된 센서를 통해 빅데이터 축적 & 분석 → 현장에서 발생하는 각종 문제 예상 및 조기 대응 가능
- **고객:** 항공기 가동률이 높아지고 수천만 달러의 운항 비용 절감
- **GE:** 빅데이터를 통한 새로운 형태의 솔루션 제공으로 새로운 수익모델 창출
- 2015년: GE의 프리딕스 매출 50억 달러 달성

미술품 감정




Authentic
or
Fake ??

1991년, 천경자 화백은 미인도는 자신의 작품이 아니라고 선언.
미인도의 소유자인 국립현대미술관은 이 작품은 천경자 화백이 그린
진품이라고 주장
천 화백 사후에 유족과 미술관 사이에 오랜 법정 분쟁으로 이어졌으나,
검찰도 천 화백의 진품이라고 주장

Art Appraisals

- 2008년, 미국 공영방송 PBS는 '미술 위작품 가려내기' 챌린지를 진행
- 참가자에게 6개의 반고(van Gogh) 작품을 보여주고 위작 가려내기: 5개의 진품 & 1개의 위작 (반고 전문가가 제작한 진품에 가까운 위작)
- 최종적으로 3 팀이 성공. PBS는 이 팀들이 위작을 가려내는 과정을 다큐로 제작하여 방영
- 성공한 팀 중 하나는 프린스턴 대학 수학과 Ingrid Daubechies 교수 팀
- **Main Idea:** 위작 제작자는 결과물이 진품과 같아야 한다는 압박에서 자유롭지 않음 → 위작품에 보이지 않는 주저함이 표현됨 → 이 주저함을 정량화 해야함
- **도브시스 교수의 혁신적 아이디어는, 그림이라는 거대 데이터에서 feature라는 작은 데이터로 이전하는 것.** → 수학의 Wavelets 이론을 사용하여, from Big Data to Small Data
- '모방작에 숨어있는 주저함의 정도'를 수학적 방식으로 추적 → 놀라운 관점의 전환



From Big Data to Small Data

거대 데이터로부터 주요 feature를 작은 데이터의 형태로
꼬집어 내는 수학적 기술의 예:

- Fourier 분해
- Wavelets 분해
- 선형대수의 SVD (Singular Value Decomposition)
- 그 외 많음....